Reprise de données : 14 ans d'archives mail → 3 bases exploitables

Schéma d'architecture du pipeline · cabinet de recrutement spécialisé en expertise comptable

SOURCES

- **Boîte A** — 1,5 Go
- **Boîte B** — < 0,1 Go
- **Boîte C** — < 0,1 Go
- **Boîte D** — 10,7 Go
- **Boîte E** — 6,1 Go

2012 → 2026 · ~30 000 mails

PIPELINE PYTHON (mailrecovery)

.pst — 18 Go
sauvegarde lecture seule

Règles métier — rules.yaml
IA — cas ambigus
Humain — valide

texte masqué avant tout appel IA

1. **Extraction** — `extract.py` — 8 607 fichiers
2. **Lecture** — `text.py` — PDF + Word
3. **Confidentialité** — `privacy.py` — mails + tél.
4. **Classification** — `classify.py` — 12 catégories
5. **Doublons** — `dedup.py` — 3 613 → 3 028
6. **Renommage** — `naming · convert` — Word → PDF
7. **Recensement** — `report.py` — 100 % traçable

BASES LIVRÉES

- **Candidats** — 3 028 CV — « NOM Prénom.pdf »
- **Administrative** — 538 documents — contrats · factures
- **Portefeuille** — 250+ placements — 350+ clients · 86 à relancer

ENTONNOIR

- **~30 000** mails
- **8 607** pièces jointes
- **3 566** documents utiles

RIEN N'EST SUPPRIMÉ PAR LE PROGRAMME : TOUT EST RANGÉ ET TRACÉ

- **_RETIRES** — **1 846 CV anonymes** — 510 privés · 216 sensibles — quittances, RIB, diplômes
- **_A_VERIFIER** — **cas incertains** — validation humaine avant toute décision
- **_DOUBLONS** — **585 CV entre boîtes** — 174 doublons exacts — version récente gardée

PROTECTION DES DONNÉES (RGPD)

- Aucune donnée réelle sur GitHub
- Contrôle automatique avant chaque envoi
- Boîtes pseudonymisées, domaine seul
- Sauvegardes .pst jamais modifiées
- CV : 2 ans après le dernier contact
- 11 tests · intégration continue

TRAJECTOIRE : RELANCE DE L'ACTIVITÉ DE RECRUTEMENT

- **Phase 0 · livré** — **Veille d'annonces, pige** — et outil de test (stage)
- **Phase 1 · livré** — **Reprise des archives mail** — ce projet
- **Phase 2 · novembre 2026** — **CRM candidats et clients** — alimenté par ces bases
- **Phase 3 · envisagé** — **Rapprochement CV ↔ offres** — recherche sémantique

Birane WANE · Data & IA · github.com/BiraneWANE/Cabinet-Rh-mail-data-recovery

Chiffres agrégés · aucune donnée personnelle