Reprise de données : archives mail → bases exploitables

Architecture du pipeline · 14 ans d'archives d'un cabinet de recrutement transformées pour relancer l'activité

5	~18 Go	~30 000	8 607	3 028	538	250+
boîtes mail Outlook, 2012 → 2026	de sauvegardes .pst	mails passés en revue	pièces jointes triées	CV exploitables	documents administratifs	placements recensés

1 — Extraction `extract.py`
Sauvegarde .pst lue en lecture seule, mails convertis, pièces jointes sorties avec date, sens et domaine.
18 Go → 8 607 fichiers

2 — Lecture `text.py`
Texte des PDF et Word, normalisé. Empreinte de contenu pour reconnaître un même CV en Word et en PDF.
empreinte SHA-1 du texte

3 — Confidentialité `privacy.py`
Détection des mails et téléphones. Un CV sans contact sort de la base. Masquage avant tout appel IA.
1 846 CV anonymes retirés

4 — Classification `classify.py + rules.yaml`
Règles métier explicables en premier, IA uniquement sur les cas ambigus, humain en dernier recours.
12 catégories

5 — Dédoublonnage `dedup.py`
Fusion des 5 boîtes. Doublons exacts (SHA-256) et de contenu. On garde la version la plus récente.
3 613 → 3 028 CV (-16 %)

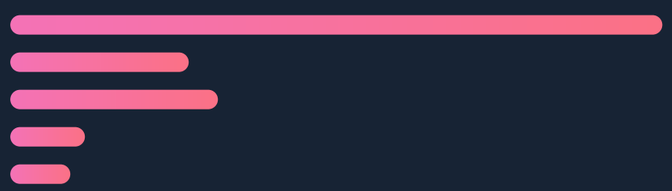
6 — Renommage + PDF `naming.py · convert.py`
« NOM Prénom », « Contrat_Société_Année ». Tous les Word convertis, homonymes protégés.
~2 900 Word → 0

7 — Recensement `report.py`
Classeur Excel de contrôle : base, à vérifier, retirés, doublons. Chaque ligne dit quelle règle a décidé.
100 % traçable

BASE LIVRÉE À LA CLIENTE

```
BASE_FUSIONNEE/
├── 1_BASE_CANDIDATS/ CV_complets · 3 028 CV « NOM Prénom.pdf »
├── 2_BASE_ADMINISTRATIVE/ · 538 documents
│   ├── Factures_et_avoirs 220 · Contrats_et_conventions 174
│   └── Documents_internes 58 · Embauches 50 · Offres 36
├── 3_PORTEFEUILLE_CLIENTS/ · 350+ clients, 86 à relancer, ~5 900 prospects
├── _RETIRES/ _DOUBLONS/ _A_VERIFIER/ · rien n'est supprimé par le programme
└── RECENSEMENT.xlsx
```

CE QUE LE TRI A ÉCARTÉ



GARDE-FOUS

- .pst jamais modifiés
- 0 donnée réelle sur GitHub
- contrôle anti-données avant chaque envoi
- boîtes pseudonymisées
- domaine seul, jamais l'adresse
- texte masqué avant l'IA
- validation humaine
- CV : 2 ans après le dernier contact
- 11 tests · intégration continue

TRAJECTOIRE

Phase 0 · livré — Veille d'annonces, pige et outil de test (stage)

Phase 1 · livré — Reprise des archives mail (ce projet)

Phase 2 · nov. 2026 — CRM candidats et clients

Phase 3 — Rapprochement CV et offres

Birane WANE · Data & IA · github.com/BiraneWANE/Cabinet-Rh-mail-data-recovery

Chiffres agrégés · aucune donnée personnelle